Nama : Demetrius Denzell Tan
NIM : 2802393030
Course: Deep Learning
Topik : Tugas GSLC Sesi 5

## Bagian A: Analisis Konseptual

1. Batch Normalization (BN) bekerja sebagai regularisasi yang lemah karena rata-rata ($\mu$) dan varians ($\sigma^2$) dihitung secara dinamis untuk setiap mini-batch, bukan untuk seluruh dataset. Fluktuasi acak dalam komposisi sampel di setiap mini-batch menambahkan noise statistik ke dalam aktivasi jaringan, yang membantu mencegah overfitting.
   Namun, asumsi bahwa BN bisa sepenuhnya menghilangkan kebutuhan dropout tidak berlaku dalam kondisi tertentu, misalnya ketika ukuran mini-batch yang digunakan terlalu kecil. Dalam ukuran batch yang sangat kecil, estimasi rata-rata dan varians menjadi tidak benar dan mengalami perubahan yang besar. Ini menyebabkan noise statistik yang masuk terlalu besar, sehingga justru mengganggu proses pelatihan, merusak kestabilan konvergensi, dan mengurangi kemampuan model dalam beradaptasi dengan data baru.
2. Di jaringan CNN biasa, menambahkan kedalaman menyebabkan masalah degradasi karena algoritma optimasi non-linear mengalami kesulitan mempelajari fungsi identitas, sehingga akurasi pelatihan menurun. Skip connection mengubah hasil output dari lapisan dengan menambahkan input asli, yaitu $y = F(x) + x$. Saat melakukan proses backpropagation, adanya komponen + x membuat turunan parsial memiliki nilai tambahan konstan + 1. Jalur pintas ini memungkinkan gradien mengalir langsung ke lapisan pertama tanpa sepenuhnya hilang karena perkalian matriks bobot yang panjang dan berulang. Mekanisme aditif itu dapat mengurangi masalah vanishing gradient, menjaga kekuatan daya sinyal kesalahan, dan memastikan proses konvergensi tetap stabil pada jaringan dengan kedalaman yang sangat besar.
3. Perbandingan antara Feature Extraction dan Fine-Tuning dilihat dari empat aspek berikut:
   - Trainable parameters:
     Dalam Feature Extraction, hanya bagian classifier yang dilatih, sehingga parameter yang diubah sedikit. Sedangkan dalam Fine-Tuning, banyak parameter yang diubah karena seluruh atau sebagian lapisan backbone diaktifkan.
   - Volume data latih:
     Feature Extraction cocok untuk data yang sedikit, sedangkan Fine-Tuning membutuhkan data yang lebih banyak supaya tidak terjadi overfitting.
   - Beban komputasi dan memori per epoch:
     Feature Extraction lebih cepat dan hemat memori karena gradien dari lapisan backbone tidak diubah. Sedangkan, Fine-Tuning memerlukan lebih banyak memori dan waktu komputasi setiap epoch.
   - Risiko kerusakan fitur:
     Feature Extraction lebih aman karena tidak ada perubahan berlebihan pada gradien yang bisa merusak fitur. Sedangkan, Fine-Tuning berisiko merusak representasi visual awal (catastrophic forgetting) jika penyesuaian terlalu berlebihan.

Gunakan Feature Extraction jika data target sedikit dan domainnya mirip dengan domain asal (seperti ImageNet). Gunakan Fine-Tuning jika domain target sangat berbeda dan jumlah data cukup banyak.

4. Pipeline data augmentation hanya diaktifkan saat menggunakan train set supaya bisa menambah variasi data tiruan, meningkatkan kemampuan generalisasi model, dan mengurangi kemungkinan overfitting. Sebaliknya, teknik tersebut harus dimatikan pada data validation/test set supaya penilaian performa model menjadi deterministik, objektif, dan benar-benar mencerminkan distribusi dunia nyata tanpa distorsi.
   Contoh teknik transformasi yang kurang benar digunakan dalam klasifikasi pet breeds adalah vertical flip atau extreme random crop pada area wajah. Tindakan ini melanggar prinsip kesetaraan makna label karena hewan peliharaan seperti kucing dan anjing biasanya tidak berada dalam posisi terbalik di dunia nyata. Selain itu, tindakan ini bisa menghilangkan iri anatomi yang penting, seperti bentuk telinga, mata, dan moncong, yang menjadi penanda utama untuk membedakan antar ras.
5. Catastrophic forgetting terjadi ketika model beradaptasi terlalu cepat, sehingga pembaruan gradien yang terlalu besar di seluruh lapisan jaringan merusak fitur visual yang sudah dipelajari sebelumnya dari dataset besar seperti ImageNet. Fitur-fitur tersebut sangat penting dan telah dipelajari secara mendalam. Dua strategi mitigasi yang bisa dilakukan untuk mencegah fenomena ini:
   - Gradual Unfreezing:
     Membuka pembekuan lapisan jaringan secara perlahan, mulai dari bagian classifier, lalu ke blok residual di bawahnya, sehingga model dapat menyerap pola domain baru secara stabil tanpa mengganggu fitur dasar secara berlebihan.
   - Differential Learning Rate:
     Menggunakan laju pembelajaran (learning rate) yang sangat keil pada lapisan backbone dan lebih besar pada lapisan classifier, sehingga bobot fitur umum terlindungi dengan baik dari perubahan yang merusak, sambil tetap memungkinkan penyesuaian parameter yang diperlukan.

Sumber referensi:


- Dataset
  Parkhi, O. M., Vedaldi, A., Zisserman, A., & Jawahar, C. (2012). *Cats and Dogs*. IEEE Conference on Computer Vision and Pattern Recognition (CVPR).

- Arsitektur ResNet-18
  He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep Residual Learning for Image Recognition*. IEEE Conference on Computer Vision and Pattern Recognition (CVPR).

- Arsitektur MobileNetV3
  Howard, A., et al. (2019). *Searching for MobileNetV3*. IEEE/CVF International Conference on Computer Vision (ICCV).

- PyTorch Framework
  Paszke, A., et al. (2019). *PyTorch: An Imperative Style, High-Performance Deep Learning Library*. Advances in Neural Information Processing Systems (NeurIPS).

- Transfer Learning and Fine-Tuning
  Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). *How transferable are features in deep neural networks?* Advances in Neural Information Processing Systems (NeurIPS).

- Bina Nusantara University. (Undefined). *Advanced CNNs and Transfer Learning*. School of Computer Science, Universitas Bina Nusantara.