Nama : Demetrius Denzell Tan
NIM : 2802393030
Course: Deep Learning
Topik : Tugas GSLC Sesi 5

Bagian C: Laporan dan Analisis

C1. Tabel Konsolidasi dan Visualisasi Pembelajaran

Tabel Konsolidasi Metrik Performa Eksperimen B1-B5

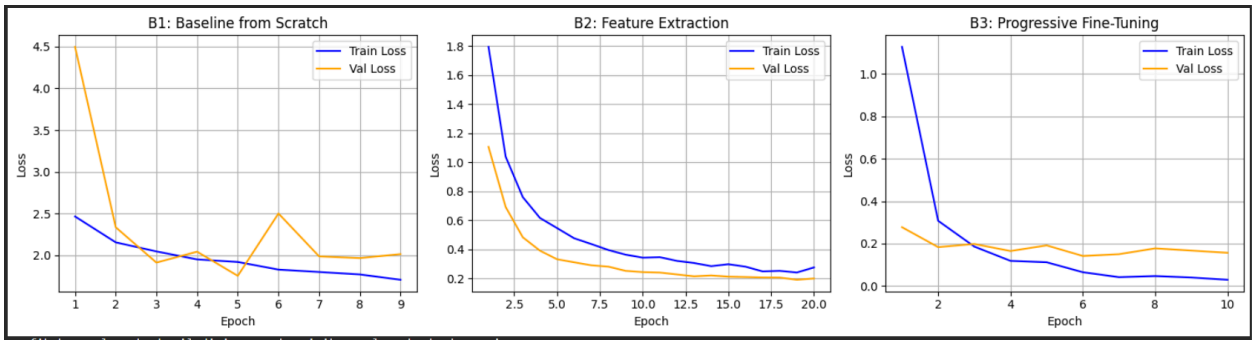
Tabel Konsolidasi Eksperimen:

	model_name	trainable_params	total_params	converged_epochs	duration_seconds	final_val_acc	test_acc	macro_f1
0	B1_FromScratch	11181642	11181642	9	101.30	0.3423	0.3706	0.3356
1	B2_FeatureExtraction	5130	11181642	20	223.32	0.9262	0.8924	0.8923
2	B3_FineTuning	8398858	11181642	10	105.75	0.9463	0.8924	0.8916
3	B4_NoAugmentation	5130	11181642	15	96.37	0.9799	0.8954	0.8946
4	B4_WithAugmentation	5130	11181642	15	155.16	0.9329	0.8863	0.8859
5	B5_MobileNetV3	1528106	1528106	9	93.10	0.8121	0.7543	0.7424

Analisis Tabel Konsolidasi

Model dasar yang dilatih dari awal (B1) mengalami masalah underfitting yang cukup parah, dengan validation accuracy hanya sebesar 34.32% dan test accuracy sebesar 37.06%, karena jumlah data yang digunakan terbatas(small-data regime). Sebaliknya, penggunaan pendekatan transfer learning dalam skenario B2 (Feature Extraction) dan B3 (Fine-Tuning) meningkatkan performa secara signifikan, masing-masing mencapai akurasi validasi sebesar 92.62% dan 94.63%, serta skor Macro F1 mendekati 0.89. Pendekatan B5 (MobileNetV3) juga menunjukkan efisiensi parameter yang cukup baik, dengan jumlah parameter total jauh lebih sedikit (1.5 juta), meskipun tingkat akurasinya sedikit lebih rendah dibandingkan ResNet-18.

Kurva Training Loss vs Validation Loss (B1, B2, B3)



Analisis Kurva Loss (B1, B2, B3)

Kurva pelatihan pada B1 menunjukkan ketidakstabilan di bagian validation loss karena kurangnya representasi awal yang cukup baik. Pada B2, kurva loss mengalami konvergensi yang stabil tetapi menurun lebih perlahan karena backbone tidak dioptimalkan. Sedangkan, kurva B3 menunjukkan konvergensi yang lebih cepat dan halus, menunjukkan bahwa membuka blok residual terakhir (layer4)

dengan differential learning rate memungkinkan model menyerap karakteristik domain tujuan secara optimal tanpa mengganggu stabilitas jaringan.

C2. Pembahasan Analisis Komparatif

1. Disparitas Performa antara Pelatihan dari Nol (B1) dengan Transfer Learning (B2 dan B3)
   Pelatihan dari awal (B1) memberikan akurasi yang rendah (~34%) karena model CNN harus belajar fitur dasar visual seperti tepi, tekstur, dan bentuk dari awal dengan data yang sangat sedikit, sehingga menyebabkan masalah underfitting yang parah. Di sisi lain, pendekatan transfer learning (B2 dan B3) menggunakan model yang sudah dilatih sebelumnya dengan dataset masif (ImageNet). Model memiliki kemampuan untuk mengenali pola objek dengan cepat dan tepat, bahkan ketika diuji menggunakan dataset yang jumlahnya terbatas.

2. Trade-off Performa vs Stabilitas (Feature Extraction vs Fine-Tuning)
   Feature Extraction murni (B2) memberikan tingkat stabilitas sangat tinggi karena semua lapisan backbone di-freeze, sehingga tidak berisiko mengalami kerusakan pada fitur-fitur tersebut. Namun, pendekatan ini memiliki kinerja maksimal yang terbatas jika domain tujuan memiliki ciri visual yang berbeda dari data sumber.
   Fine-Tuning bertahap (B3) memberi performa lebih fleksibel karena membuka lapisan yang lebih dalam secara perlahan, sehingga model bisa menyesuaikan diri secara spesifik dengan detail dari domain target. Meski begitu, pendekatan ini memerlukan kewaspadaan karena bisa menyebabkan catastrophic forgetting jika tidak dikontrol dengan tingkat pembelajaran yang sesuai.

3. Peran Augmentasi Data (B4) dalam Meredam Overfitting
   Teknik data augmentation (seperti flip, rotation, dan color jitter) digunakan untuk membuat data latih tambahan dengan menciptakan variasi bentuk dan tampilan gambar. Berdasarkan perbandingan kondisi B4, augmentasi efektif membantu mengurangi perbedaan (generalization gap) antara performa data latih dan data validasi, mencegah model melakukan memorization murni, serta meningkatkan kemampuan model untuk beradaptasi pada data uji di dunia nyata.

C3. Failure Analysis (Analisis Kasus Misklasifikasi)



Gambar di atas berupa 8 sampel citra dari test set yang mengalami kesalahan prediksi oleh model terbaik yang saya train. Berikut adalah rincian dan hipotesis penyebab kesalahan untuk setiap sampel (atas kiri merupakan sampel, dan bergerak ke kanan untuk sampel selanjutnya):

1. Sampel 1
   Ground Truth: Abyssinian
   Prediction: American Pit Bull Terrier (Conf. 49.6%)
   Hipotesis: Adanya kebanyakan objek dekoratif di sekitar kucing mengganggu ekstraksi fitur backbone, sehingga membuat model salah mengenali konteks latar sebagai ciri khas anjing.
2. Sampel 2 dan 3
   Ground Truth: Abyssinian
   Prediction: Bengal (Conf. 77.0% dan 61.7%)
   Hipotesis: Ras Abyssinian dan Bengal memiliki rambut pendek dengan warna yang sangat mirip, sehingga pemisah fitur visual antar kedua class ini sangat tipis bagi model.
3. Sampel 4
   Ground Truth: Abyssinian
   Prediction: American Pit Bull Terrier (Conf. 41.3%)
   Hipotesis: Pose kepala kucing yang melihat ke atas mengubah bentuk telinga dan moncong, menjadi menyerupai wajah anjing Pit Bull.
4. Sampel 5
   Ground Truth: Abyssinian
   Prediction: Bengal (Conf. 57.8%)
   Hipotesis: Posisi kucing yang terbalik merupakan anomali dari fitur anatomi yang dipelajari model.
5. Sampel 6
   Ground Truth: Abyssinian
   Prediction: Bengal (Conf. 68.8%)
   Hipotesis: Adanya bayangan gelap dan cahaya matahari dari samping menyamarkan tekstur dan pola garis bulu asli kucing.
6. Sampel 7
   Ground Truth: Abyssinian
   Prediction: British Shorthair (Conf. 85.9%)
   Hipotesis: Posisi kucing yang sedang tidur menutup sebagian besar identifikasi wajah, sehingga model salah mendeteksinya sebagai ras British Shorthair dengan confidence rate yang cukup tinggi.
7. Sampel 8
   Ground Truth: Abyssinian
   Prediction: Bengal (Conf. 84.9%)
   Hipotesis: Sampel ini memiliki warna bulu yang sangat mirip dengan karakteristik ras Bengal pada dataset ImageNet.

C4. Rekomendasi Rekayasa dan Batasan Eksperimen

1. Rekomendasi Praktis bagi Tim Rekayasa Industri
   Berdasarkan hasil percobaan pada kondisi data terbatas, strategi pelatihan yang terbaik untuk digunakan di lingkungan produksi adalah Progressive Fine-Tuning (B3). Pendekatan ini

terus-menerus memberikan akurasi validasi yang tinggi (~94.63%) serta efisiensi dalam waktu konvergensi, karena mampu menjaga representasi visual umum dari backbone sekaligus menyesuaikan lapisan dalam (layer4) sesuai dengan karakteristik domain tujuan.

Kondisi Berlakunya (Operational Constraints):

- Strategi ini bekerja baik jika domain data target memiliki kesamaan atau berasal dari domain umum, seperti objek visual alami yang sesuai dengan pretrained weights ImageNet).
- Dibutuhkan infrastruktur komputasi dengan GPU minimal kelas konsumen atau cloud tier ringan, seperti GPU T4.
- Pipeline data augmentation harus diintegrasikan pada tahap pelatihan supaya menghindari overfitting yang disebabkan oleh keterbatasan jumlah sampel.
- Jika anggaran komputasi terbatas dan durasi pelatihan pendek, metode Feature Extraction murni (B2) bisa dipilih sebagai alternatif yang efisien dengan performa yang kompetitif.

2. Batasan dan Limitasi Studi

   Studi eksperimental ini memiliki beberapa keterbatasan dalam ruang lingkup yang peru diperhatikan:

   - Eksperimen dijalankan menggunakan satu nilai random seed tetap (seed = 42), sehingga belum diperiksa secara menyeluruh bagaimana variasi hasilnya ketika menggunakan inisialisasi acak yang berbeda.
   - Evaluasi data terbatas hanya mencakup 10 kelas dari total 37 kelas yang ada di dataset Oxford-IIIT Pet, sehingga kompleksitas klasifikasi dengan jumlah kelas yang besar belum sepenuhnya dieksplorasi.
   - Penelitian ini fokus pada arsitektur CNN dengan ukuran kecil hingga menengah, seperti ResNet-18 dan MobileNetV3-Small. Penelitian ini tidak membandingkan hasilnya dengan arsitektur modern yang lebih besar, seperti EfficientNet tingkat lanjut atau Vision Transformers (ViT).

Pernyataan Penggunaan AI

Dalam pembuatan tugas dan laporan analisis tugas ini, saya memanfaatkan bantuan Artificial Intelligence (AI) dengan detail sebagai berikut:

1. Nama Model / Alat AI yang digunakan

   Gemini

2. Ruang Lingkup Bantuan AI pada Tugas Ini
   - Membantu menyusun kerangka penjelasan analitis untuk pertanyaan esai dan menjawab pertanyaan-pertanyaan saya mengenai topik yang bersangkutan.
   - Membantu merancang dan debugging code Python pada Google Colab.
   - Membantu menuliskan draf struktur narasi untuk laporan analisis.
3. Cara Verifikasi Kebenaran Secara Mandiri
   - Seluruh code block dan fungsi visualisasi yang disarankan sudah diuji dan dirun di dalam lingkungan Google Colab saya untuk memastikan akurasi data sesuai log eksperimen (metrics_log.json dan metrics_log.csv).
   - Setiap poin penjelasan dan analisis sudah diperiksa ulang dan disesuaikan dengan materi slide Binus untuk memastikan kebenarannya secara ilmiah dan kesesuaian konteks tugas,